

Tests discrets usuels, puis introduction aux tests multiples

E. Halouani et L. Bertrand
eliot.halouani@universite-paris-saclay.fr
lucas.bertrand@universite-paris-saclay.fr

Université Paris-Saclay – Double Licence Mathématiques et Sciences de la Vie
Projet encadré proposé par Guillermo Durand



Introduction

Les tests d’hypothèses sont utilisés pour déterminer si des observations résultent du hasard ou révèlent un effet significatif. Ce projet s’intéresse dans un premier temps au test exact de Fisher, dédié à l’étude de l’indépendance entre deux variables binaires, ainsi qu’au test binomial appliqué à la comparaison de paramètres de lois de Poisson.

Dans un second temps, nous abordons la problématique des tests multiples, où la réalisation simultanée d’un grand nombre de tests augmente le risque de faux positifs. Nous étudions plusieurs procédures de correction, telles que Bonferroni, Holm-Bonferroni et Benjamini–Yekutieli, afin d’évaluer leur capacité à contrôler les taux d’erreur tout en préservant la puissance statistique. Les propriétés théoriques de ces méthodes sont illustrées par des simulations réalisées sous R.

1. Test exact de Fischer

On observe un échantillon de couples indépendants

$$Z = ((X_1, Y_1), \dots, (X_n, Y_n)),$$

où X et Y sont deux variables de Bernoulli. On note

$$p_{ij} = \mathbb{P}(X = i, Y = j), \quad i, j \in \{0, 1\},$$

et

$$N_{ij} = \sum_{k=1}^n \mathbb{1}_{\{X_k=i, Y_k=j\}}.$$

Tableau de contingence

	$Y = 0$	$Y = 1$	Total
$X = 0$	N_{00}	N_{01}	$N_{0.}$
$X = 1$	N_{10}	N_{11}	$N_{1.}$
Total	$N_{.0}$	$N_{.1}$	n

L’hypothèse testée est

$$H_0 : X \perp Y \iff \text{“}X \text{ et } Y \text{ sont indépendantes”}$$

C’est à dire que sous H_0 , on a :

$$p_{ij} = p_i \cdot p_j.$$

Loi multinomiale

Les quatre effectifs du tableau suivent une loi multinomiale :

$$(N_{00}, N_{01}, N_{10}, N_{11}) \sim \mathcal{M}(n, (p_{00}, p_{01}, p_{10}, p_{11})).$$

Loi conditionnelle sous H_0

Le résultat fondamental du test exact de Fisher est le suivant :

Sous H_0 , conditionnellement aux marges,

$$N_{00} \mid (N_{0.}, N_{.0}) = (n_{0.}, n_{.0}) \sim \mathcal{H}(n, n_{0.}, n_{.0}).$$

Construction du test

On cherche une région de rejet de la forme

$$R = \{N_{00} > c\}.$$

Si

$$T \sim \mathcal{H}(n, n_{0.}, n_{.0}),$$

alors on choisit

$$c = q_{1-\alpha}^{\mathcal{H}(n, n_{0.}, n_{.0})},$$

c’est-à-dire le quantile d’ordre $1 - \alpha$.

La zone de rejet est donc

$$R = \left\{ N_{00} > q_{1-\alpha}^{\mathcal{H}(n, n_{0.}, n_{.0})} \right\}.$$

Le test inconditionnel s’obtient en recalculant ce seuil à partir des marges observées :

$$\varphi(Z) = \mathbb{1}_{\{N_{00} > q_{1-\alpha}^{\mathcal{H}(n, N_{0.}, N_{.0})}\}}.$$

P-valeurs et super-uniformité

La p-valeur conditionnelle associée au test est

$$p(Z) = \sup_{P \in H_0} \mathbb{P}_{\mathcal{L}((X', Y'))=P}(N_{00}(Z') \geq N_{00}(Z) \mid (N_{0.}(Z'), N_{.0}(Z')) = (N_{0.}(Z), N_{.0}(Z))).$$

Si k est une valeur possible de N_{00} , on pose

$$p_k = \mathbb{P}(T \geq k), \quad T \sim \mathcal{H}(n, n_{0.}, n_{.0}).$$

Alors

$$p(Z) = p_k \iff N_{00}(Z) = k.$$

Sous H_0 , la p-valeur est super-uniforme (voir figure 2) :

$$\forall x \in \mathbb{R}, \quad F_{p(Z)}(x) \leq U(x),$$

où U est la fonction de répartition d’une loi uniforme sur $[0, 1]$. Le test basé sur la p-valeur est

$$\varphi_p(Z) = \mathbb{1}_{\{p(Z) \leq \alpha\}},$$

Il est de niveau α et équivalent à celui ci-dessus.

Les valeurs simulées de N_{00} se superposent à la fonction de masse théorique (voir figure 1) . Cela confirme expérimentalement la loi conditionnelle hypergéométrique obtenue sous H_0 .




Figure 1: Superposition de l’histogramme des valeurs simulées de N_{00} et de la fonction de masse de la loi hypergéométrique $\mathcal{H}(n, n_{0.}, n_{.0})$.




Figure 2: Répartition de 1000 p-valeurs comparées avec 1000 tirages d’une loi uniforme (gauche) et comparaison entre la fonction de répartition théorique et empirique des p-valeurs sous conditionnement (droite).

2. Test binomial

On considère deux variables indépendantes

$$Y_1 \sim \mathcal{P}(\lambda_1), \quad Y_2 \sim \mathcal{P}(\lambda_2),$$

et on teste

$$H_0 : \lambda_1 = \lambda_2.$$

Sous H_0 , conditionnellement à $Y_1 + Y_2 = s$, on obtient

$$Y_1 \mid (Y_1 + Y_2 = s) \sim \mathcal{B}(s, 1/2).$$

On retrouve donc la même logique que pour le test exact de Fisher : conditionner élimine le paramètre inconnu λ .

De manière similaire à la partie précédente, le test inconditionnel est le suivant:

$$\varphi(Y_1, Y_2) = \mathbb{1}_{\left\{Y_1 > q_{1-\alpha}^{\mathcal{B}(Y_1+Y_2, 1/2)}\right\}}.$$

Superposition des valeurs prises par Y_1 conditionnellement à $Y_1 + Y_2 = n$ (gris) et de la fonction de masse de probabilité de $\mathcal{B}(n, 1/2)$ (magenta)




Figure 3: Superposition de l’histogramme des valeurs simulées de Y_1 et de la fonction de masse de la loi binomiale $\mathcal{B}(n, 1/2)$.

***latex




Figure 4: Répartition de 1000 p-valeurs comparées avec 1000 tirages d’une loi uniforme (gauche) et comparaison entre la fonction de répartition théorique et empirique des p-valeurs sous conditionnement (droite).

3. Tests multiples

Lorsqu’on réalise simultanément m tests, la probabilité de faire au moins un faux positif augmente rapidement avec m . Si r désigne la probabilité de rejet d’un test sous H_0 , alors

$$\mathbb{P}(\text{au moins un faux positif}) = 1 - (1 - r)^m.$$




Figure 5: Évolution du $FWER$ empirique sans la procédure de Bonferroni.

Le *Family-Wise Error Rate* est défini par

$$FWER(R) = \mathbb{P}(V(R(Z)) > 0),$$

où $V(R(Z))$ est le nombre de faux positifs. Contrôler le $FWER$ au niveau α , c’est donc garantir que

$$FWER(R) \leq \alpha.$$

La procédure de Bonferroni consiste à tester chaque hypothèse au niveau

$$\frac{\alpha}{m}.$$

Ainsi,

$$FWER(R) \leq \sum_{i \in H_0} \mathbb{P}\left(p_i \leq \frac{\alpha}{m}\right) \leq |H_0| \frac{\alpha}{m} \leq \alpha.$$

Bonferroni contrôle donc le $FWER$ au niveau α .

On définit aussi le k - $FWER$ par

$$k\text{-}FWER(R) = \mathbb{P}(V(R(Z)) \geq k).$$

La procédure de Bonferroni modifiée teste chaque hypothèse au niveau

$$\frac{\alpha k}{m}.$$

Par l’inégalité de Markov,

$$k\text{-}FWER(R) \leq \frac{\mathbb{E}[V(R(Z))]}{k} \leq \frac{\alpha k}{k} = \alpha.$$

Elle contrôle donc le k - $FWER$ au niveau α .